

Agentic Embodiment 综述 · 第二轮进展

定义、分类与核心论文表 · 2026-10-08 · 分支 `claude/compassionate-sagan-wklsz6`

一句话定义 Agentic Embodiment 研究由基础模型驱动、做出显式决策的过程：决策的后果作用到机器人身体上，过程再依据后果的证据重新决策。全文围绕一个问题组织：这个过程相对于机器人部署的策略坐在哪里（**Seat**），由哪类权重承载（**Carrier**）。

Agentic Embodiment studies foundation-model-driven processes that make explicit decisions whose consequences reach a robot body, and that re-decide on evidence of those consequences. Its organizing question is where such a process sits relative to the body's deployed policy — steering it, guarding it, teaching it, designing its learning problem, or building its system (Seat) — and which weights carry it (Carrier).

主线：Agency spreads around the body — and loop closure, not weights, makes a carrier an agent.

agency 没有离开机器人，而是在身体周围占据越来越多的位置；一个模型算不算 agent，取决于它是否闭合了「带着自身记录、依据后果再决策」的环，而不是它用的是哪套权重。

13,579

篇候选论文
(种子的前向引用)

1,406

篇逐篇判定
(15 个 Sonnet
agent)

57 + 8

篇核心 + 前驱
(人工挑选)

14

个 benchmark
与资源

79/79

篇经 arXiv 核验
(标题全部一致)

本轮结论

- 框架已定**：你确认了四项决策：采用 Seat × Carrier；开环奠基作作为「前驱」进核心表；核心集约 60 篇；自动驾驶与离散仿真只作边界讨论。
- 核心表**：Controller 26、Supervisor 8、Teacher 6、Designer 8、Developer 9；前驱 8；资源 14。你点名的 5 篇（GUAVA、Harness VLA、Show-Harness、ENPIRE、Code-as-Monitor）都在表内。
- 主线有数据支撑**：在全部 214 篇判为 core 的论文上，有效 seat 数从 1.00（2022）升到 3.60（2026）；含 Controller 的论文占比 2023–2026 年一直在 71%–76%。seat 在增加，而不是从 Controller 迁走。
- 判定可靠**：第一轮测试集里判为 CORE 的 70 篇，Sonnet 判 core 的有 68 篇，其中 65 篇主 seat 一致。

需要你决定

- 规模**：现在核心 57 + 前驱 8 = 65 篇，比约定的 60 篇多 5 篇。我建议保留，因为仍在「约 60」的范围内；如果要压到 60，建议去掉 Agent as Policy、VIA、VLMgineer、Skill2Real、SUDD。
- 候补**：附录 B 列了因名额没收的论文。有想换进来的告诉我。
- 合并到 main**：所有内容目前在工作分支上，main 上的 README 还是空的。需要的话我开 PR。

1 这一轮做了什么

第一轮已经把 14 篇种子论文的前向引用收割完，并做了粗筛和短名单。这一轮在此基础上逐篇判定、挑出核心表，并补全元数据。下图是完整的筛选漏斗，右栏标出每一步由谁完成。




图 1 筛选漏斗。前四步是第一轮的工作，后三步是这一轮。粗筛用最便宜的 Haiku；逐篇判定要套用细致的定义，所以用 Sonnet；最后一步由人工挑选。

这一轮的四个关键做法

- 补判定池：**短名单按被引数和新兴度取样，会漏掉被引中等、但属于小 seat 的论文，例如 Code-as-Monitor (83 引，2024 年 12 月)。所以补了 621 篇小 seat 论文 (monitor、teacher、developer 等的门槛更低) 和 159 篇第一轮测试集论文。
- 逐篇判定：**每个 Sonnet agent 读约 94 篇的标题和摘要，按 rubric 给出 verdict、seat、carrier、子类、接口、代表性 (1-5 分) 和一句理由；合并时校验了枚举值和完整性，没有漏标。
- 联网补漏：**一个 agent 用 WebSearch 和 arXiv API 查找池中缺失的公认工作，找到 50 篇，全部经 arXiv 核验 (core 32、资源 14、前驱 4)。EmbodiedBench、Embodied Agent Interface 等 benchmark 和 BUMBLE、VLM-PC 由此补入。
- 人工挑选：**每个 seat 内按代表性和影响力排序，再兼顾年份、领域 (操作、移动操作、导航、足式、人形、多机器人) 和 carrier 的覆盖。每篇写了中文入选理由，见附录 A。

2 定义：什么算 agent

判定对象是「模型 + harness + 环」构成的过程，不是权重本身。同一族小模型放进 GUAVA 的 harness 里是 agent，在 Show-Harness 的单 token 模式下就只是反应式策略。下图是逐篇判定时的顺序：




图 2 agent 判定流程。①–③ 是三条 agent 判定，必须全部满足；④ 决定进核心还是只作边界讨论。③ 不满足的奠基作，按你的决定作为「前驱」进核心表。

三个常见误区

- **RL 微调不等于 agency**：SimpleVLA-RL 一类判 OUT，因为没有显式决策。
- **架构内的 memory 不等于 agency**：MemoryVLA 一类判 OUT。agent 自己读写的 memory 才计入。
- **多机器人不等于 multi-agent**：一个 LLM 调度多台机器人 (SMART-LLM)，topology 记为 1:N。

3 分类：五个 Seat × 四类 Carrier

主轴 Seat 回答「agent 坐在哪里」。判定依据是 agent 的输出在什么阶段产生、由谁消费：评测时被调用的是 Controller 或 Supervisor；部署前产出、冻结后再交给系统的是 Teacher、Designer 或 Developer。




图 3 五个 Seat 围绕机器人身体。右侧两个 seat 在评测时工作：Controller 持续驱动，Supervisor 只在异常时介入。左侧三个 seat 在部署前工作，产出冻结后进入部署的系统。ENPIRE 部署出去的策略里没有 agent，但它仍是核心样本，因为 agent 坐在 Developer 的位置。

副轴 Carrier 回答「决策由哪类权重承载」。你最初的「agency 在哪里」四类，正好对应 Controller 一行的四列：外部编排 → G / C；分层双系统 → H；内化 → I；multi-agent 不再是类别，改为 Topology 列。

Seat	G 作者未做具身训练的通用模型	C 训练过的决策者 + 通用执行器	H 训练过的决策者 + 协同设计的执行器	I 同一个模型既决策又出动作	合计
Controller 控制者	21 Harness VLA ★、Show-Harness ★...	1 PaLM-E	2 Hi Robot、Gemini Robotics 1.5	2 OneTwoVLA、MEM	26
Supervisor 监督者	7 Code-as-Monitor ★、REFLECT...	.	1 Phoenix	.	8
Teacher 教师	6 GUAVA ★、RoboTwin 2.0... 含 2 篇 G→C 迁移	.	.	.	6
Designer 设计者	8 Eureka、DrEureka...	.	.	.	8
Developer 开发者	9 ENPIRE ★、ASPIRE...	.	.	.	9

篇数：1-2 3-5 6-9 ≥10 ★ 用户点名

图 4 核心表的 Seat × Carrier 网格。格中是篇数和代表论文，颜色越深篇数越多。规律很明显：外环的三个 seat（Teacher、Designer、Developer）全部由 G 类通用模型承担；训练过的 carrier（C / H / I）只出现在评测时的 seat。GUAVA 和 LocalNav 把 G 的行为蒸馏成 C，是目前仅有的跨格迁移。

4 核心论文全景

下图把 57 篇核心论文和 8 篇前驱按 seat 和 arXiv 首版年份排开。每个色块是一篇论文，★ 是你点名的案例。完整的表格（会议、carrier、接口、身体、入选理由）见附录 A。

Controller 的四个子章

Controller 在核心表中有 26 篇，正文按接口拆为四个子章：**编排型** 11 篇（调用技能、工具或 VLA，如 SayCan、BUMBLE）；**直接驱动型** 6 篇（输出语义微动作或当下执行的代码，如 Show-Harness、CaP-X，对应 robot-use agent 社区）；**lifelong / memory 型** 4 篇（评测期间写入并读取 memory 或技能库，如 Harness VLA、DROC）；**训练过的 carrier** 5 篇（PaLM-E、Hi Robot、OneTwoVLA 等）。harness 和 multi-agent 都不是类别：harness 属于接口，multi-agent 属于 topology。

	2022	2023	2024	2025	2026
Controller 编排型 · 11	SayCan Inner Monologue	RoCo	MOSAIC COME-robot VLM-PC BUMBLE	Being-0 Agentic Robot	RoboClaw Thea
Controller 直接驱动型 · 6			InstructNav		FAEA CaP-X VIA Show-Harness ★ Agent as Policy
Controller lifelong 型 · 4		DROC	LRLl		Harness VLA ★ MessyMem
Controller 训练过的 carrier · 5		PaLM-E		Hi Robot OneTwoVLA Gemini Robotics 1.5	MEM
Supervisor 监督者 · 8		REFLECT DoReMi	Code-as-Monitor ★	Phoenix RoboSafe	CycleVLA FRAMES WhenToAsk
Teacher 教师 · 6			Manipulate-Anything	RoboTwin 2.0	GUAVA ★ LocalNav EmbodiedSWE RHD
Designer 设计者 · 8		Eureka	OMNI-EPIC REvolve CurricuLLM Eurekaverse DrEureka	Video2Policy	FIND
Developer 开发者 · 9			RoboMorph	VLMgineer	HARBOR RHO RATs (Playful) ENPIRE ★ ASPIRE SimEX Skill2Real
前驱 precursor · 8	ZS-Planners Code as Policies ProgPrompt	KnowNo VoxPoser SUDD	ECot	π0.5	

图 5 核心论文按 Seat 与年份分布。从左往右看，2022 年只有 Controller；2023 年出现 Supervisor 和 Designer；2024 年出现 Teacher 和 Developer；2026 年五个 seat 都很密集。这只是挑选结果的分布，有名额的影响，趋势证据见第 5 节。

5 趋势证据

核心表是按名额挑的，不能当趋势证据。所以下面用全部 214 篇判为 core 的论文统计。需要注意：判定池按影响力和新兴度取样，2026 年占一半（108 篇），所以只看各年内部的结构，不看绝对数量。





图 6 各年份主 seat 的占比。每篇论文按主 seat 计一次。Controller 一直是多数，但 2026 年 Developer 一下子占到约五分之一。不足以放下标签的色块，数值见下表。

有效 seat 数

把每年各 seat 的论文数当成分布，取熵的指数；1 表示只有一个 seat



含 Controller 的论文占比

主 seat 或次 seat 含 Controller 的论文 ÷ 该年论文数




图 7 主线的两个支撑。左：seat 越来越分散（1.00 → 3.60）。右：含 Controller 的论文占比基本不变（2023 年后在 71%–76%）。两者合起来就是「seat 在增加，而不是迁移」。

年份	n	Controller	Supervisor	Teacher	Designer	Developer	含 Controller	含 Developer	有效 seat 数
2022	3	3 (3)	0 (0)	0 (0)	0 (0)	0 (0)	100%	0%	1.00
2023	21	14 (16)	2 (2)	2 (2)	3 (4)	0 (0)	76%	0%	2.67
2024	44	31 (33)	3 (8)	1 (1)	7 (7)	2 (5)	75%	11%	3.14
2025	38	25 (27)	6 (7)	4 (4)	2 (5)	1 (1)	71%	3%	3.14
2026	108	64 (81)	7 (18)	8 (10)	7 (12)	22 (27)	75%	25%	3.60

各 seat 一栏：主 seat 篇数（括号内为主 seat 或次 seat 含该 seat 的篇数）。

怎么读这些数字

- Developer 是 2026 年的新现象：含 Developer 的论文 2022–2023 年为 0，2024 年 11%、2025 年 3%，2026 年 25%。2024 年的数字来自 RoboMorph、InterPreT、LRLL 等 5 篇。
- 结论只在「全部 seat」口径下稳健：一篇论文常有多多个 seat，正文必须写明统计单位。
- 还不是独立样本：投稿前应按草稿 § 10 的方案，从候选中分层随机抽样，两人盲标后复核这两个趋势。

6 下一步

需要你决定的三件事见第 1 页。其中规模一项：压到 60 篇时建议去掉 Agent as Policy、VIA、VLMgineer、Skill2Real、SUDD，这五篇所在的子类里都还有其他代表作；候补的 14 篇见附录 B，比如想补无人机方向，可以把 REAL 换进来。

- 1. **冻结核心表**：你审阅后，我按你的意见改 core_selection.csv 并重新生成 README 和这份报告。
- 2. **补全链接**：目前只有 27/79 篇能从 arXiv comment 中提取到项目或代码链接，其余需要联网逐篇查。
- 3. **全文审计**：25 篇 2026 年的核心论文只按摘要判过。优先核实 Agent as Policy、VIA、FAEA、Thea、RATs、Skill2Real 的 seat 和闭环判定。
- 4. **写正文**：按 Seat 分章，Controller 拆四个子章；第 5 节的数字作为趋势证据。
- 5. **可选**：做一个类似 WAM survey 的 GitHub Pages 浏览器；对已有 survey 做反向滚雪球，进一步提高查全率。

附录 A 核心论文表

短名链接到 arXiv；年份为 arXiv 首版；会议来自 Semantic Scholar，未发表的记为 arXiv；★ 为用户点名。Carrier 中的 G→C 表示从通用模型蒸馏到训练过的模型。

Controller • 编排型 (11)

短名	年份	会议	Carrier	接口	身体	入选理由
SayCan	2022	CoRL	G	技能调用	移动操作 • 真机	奠基作：LLM 与 affordance 组合，逐步在异质 skill 中选择，执行后重新调用；Controller 的起点
Inner Monologue	2022	CoRL	G	技能调用	操作 • 仿真+真机	奠基作：成功检测与人类反馈回灌提示，典型闭环规划者
RoCo	2023	ICRA	G	技能调用	多机器人 • 仿真+真机	多机器人对话协商 (×N) 的代表；种子论文
MOSAIC	2024	CoRL	G	技能调用	多机器人 • 真机	1:N 拓扑代表：LLM 规划者与用户对话并调度两台机器人协作烹饪
COME-robot	2024	ICRA	G	技能调用	移动操作 • 真机	GPT-4V 闭环开放词表移动操作，执行反馈驱动重规划；覆盖 mobile-manip
VLM-PC	2024	ICRA	G	技能调用	足式 • 真机	足式机器人：VLM 依上下文历史选择并重规划运动技能以应对障碍；覆盖 loco
BUMBLE	2024	ICRA	G	技能调用	移动操作 • 真机	VLM 统一感知、粗到细技能与双层 memory，楼宇级长程移动操作，90+ 小时真机评测
Being-0	2025	arXiv	G	技能调用	人形 • 真机	人形机器人 agent：FM 规划 + VLM connector 调用技能；覆盖 humanoid
Agentic Robot	2025	arXiv	G	VLA 调用	操作 • 仿真	推理模型分解子目标、VLA 执行、verifier 逐子目标检查；VLA-as-tool 编排 (2025)
RoboClaw	2026	arXiv	G	技能调用	操作 • 真机	单 VLM 控制器统一数据采集、策略学习与执行，编排学习型原语并自复位 (43 引)
Thea	2026	arXiv	G	技能调用	移动操作 • 真机	把 coding-agent harness 范式迁移到具身：工具化能力 + 场景图上下文；2026 harness 浪潮代表

Controller • 直接驱动型 (6)

短名	年份	会议	Carrier	接口	身体	入选理由
InstructNav	2024	CoRL	G	约束	导航 • 仿真	零样本通用指令导航，LLM 反复重规划 Dynamic Chain-of-Navigation；覆盖 nav
FAEA	2026	arXiv	G	代码	操作 • 仿真	软件工程 agent 框架不改动直接用于操作 (LIBERO 等)，robot-use agent 代表
CaP-X	2026	arXiv	G	代码	操作 • 仿真+真机	coding agent 写当下执行的控制代码并依视觉差分反馈修正；CaP 的闭环继承者与评测框架

VIA	2026	arXiv	G	语义微动作	操作 · 仿真+真机	FM 通过浏览器式 3D 界面像操作软件一样驱动机械臂；接口新颖
Show-Harness ★	2026	arXiv	G	语义微动作	操作 · 仿真+真机	用户点名：前沿 VLM 输出语义微动作由确定性解释器执行，零样本真机
Agent as Policy	2026	arXiv	G	代码	操作 · 真机	通用 agent 写程序、发运动指令并依物理结果修订，直接驱动真机

Controller · lifelong / memory 型 (4)

短名	年份	会议	Carrier	接口	身体	入选理由
DROC	2023	ICRA	G	代码	操作 · 真机	整合在线语言纠正修订计划与技能代码，并蒸馏检索知识 (H closure)
LRLl	2024	ICRA	G	代码	操作 · 仿真	LLM 在技能库上写策略代码并通过 memory 与自提任务扩库；lifelong 早期代表
Harness VLA ★	2026	arXiv	G	代码	操作 · 仿真+真机	用户点名：冻结 VLA 作为工具，agent 重落地与重摆放，memory 跨 episode 学习
MessyMem	2026	arXiv	G	技能调用	移动操作 · 仿真+真机	持久 3D 场景图 memory 随交互结果更新的移动操作 agent

Controller · 训练过的 carrier (5)

短名	年份	会议	Carrier	接口	身体	入选理由
PaLM-E	2023	ICML	C	技能调用	移动操作 · 真机	训练过的 carrier (C) 奠基作：多模态 LLM 输出计划供低层策略执行；种子论文
Hi Robot	2025	ICML	H	VLA 调用	移动操作 · 真机	分层 H 的代表：高层 VLM 输出下一步指令并响应用户反馈，低层协同设计
OneTwoVLA	2025	arXiv	I	语义微动作	操作 · 真机	内化 I 的代表：单一 VLA 自适应地决定何时推理、维护历史并从错误恢复
Gemini Robotics 1.5	2025	arXiv	H	VLA 调用	操作 · 真机	厂商 ER 编排者 + 自家 VLA (协同设计)，规划、估计进度并调用工具
MEM	2026	arXiv	I	技能调用	移动操作 · 真机	VLA 输出子任务语言并更新自身文本记忆 (多尺度记忆, 76 引)

Supervisor · 监督者 (8)

短名	年份	会议	Carrier	接口	身体	入选理由
REFLECT	2023	CoRL	G	裁决	操作 · 仿真+真机	奠基 Supervisor：总结机器人经验解释失败，解释驱动纠正 (296 引)
DoReMi	2023	IROS	G	裁决	操作 · 仿真+真机	LLM 写约束、VLM 持续监测违例并触发恢复与重规划
Code-as-Monitor ★	2024	CVPR	G	裁决	操作 · 仿真+真机	用户点名：VLM 编写约束监测代码逐帧执行，违例或预测违例时重规划
Phoenix	2025	CVPR	H	VLA 调用	操作 · 仿真+真机	运动级自我反思：MLLM 输出运动纠正指令给协同训练的执行器；Supervisor 中的 H
RoboSafe	2025	arXiv	G	裁决	操作 · 仿真+真机	可执行安全谓词在运行时拦截危险动作并触发重规划；安全方向代表
CycleVLA	2026	arXiv	G	裁决	操作 · 仿真	VLM 预测失败并触发子任务回退与重试，主动自纠正的 VLA 监督
FRAMES	2026	arXiv	G	裁决	人形 · 仿真+真机	人形机器人多视角技能监测与恢复 (×R)
WhenToAsk	2026	arXiv	G	裁决	操作 · 仿真+真机	失败后在恢复、补充感知和向人求助之间选择；人机对话式恢复

Teacher · 教师 (6)

短名	年份	会议	Carrier	接口	身体	入选理由
Manipulate-Anything	2024	CoRL	G	技能调用	操作 · 仿真+真机	VLM 分解、执行、验证并重规划，经验证轨迹训练行为克隆策略（125 引）
RoboTwin 2.0	2025	arXiv	G	代码	操作 · 仿真+真机	MLLM 写任务代码并经仿真闭环修正，合成经验证的示范（571 引）
GUAVA ★	2026	arXiv	G→C	执行轨迹	操作 · 仿真+真机	用户点名：前沿 VLM 在 harness 中行动的轨迹蒸馏为 4B agent，同接口 agent→agent 迁移
LocalNav	2026	arXiv	G→C	技能调用	导航 · 仿真	前沿 VLM 导航 agent 轨迹蒸馏到端侧 4B VLM；覆盖 nav 的 Teacher
EmbodiedSWE	2026	arXiv	G	代码	操作 · 仿真+真机	coding agent 迭代编写调试灵巧操作程序，经验证解扩展为训练示范
RHD	2026	arXiv	G	执行轨迹	操作 · 仿真+真机	强 agent 的经验提炼成 playbook 供轻量 agent 使用（in-context 迁移）

Designer · 设计者 (8)

短名	年份	会议	Carrier	接口	身体	入选理由
Eureka	2023	ICLR	G	问题规格	操作 · 仿真	奠基 Designer：LLM 写奖励代码并依 RL 训练统计反思进化
OMNI-EPIC	2024	arXiv	G	问题规格	足式 · 仿真	FM 写环境、奖励与成功代码，开放式任务生成
REvolve	2024	ICLR	G	问题规格	人形 · 仿真	人类反馈 + 训练结果驱动奖励进化（H closure）
DrEureka	2024	RSS	G	问题规格	足式 · 仿真+真机	奖励 + domain randomization 设计，四足 sim-to-real
CurricuLLM	2024	ICRA	G	问题规格	人形 · 仿真	LLM 生成子任务课程与奖励代码，依策略结果推进
Eurekaverse	2024	CoRL	G	问题规格	足式 · 仿真+真机	LLM 写地形环境代码并依训练结果迭代课程
Video2Policy	2025	arXiv	G	问题规格	操作 · 仿真	从视频重建仿真任务并依 RL 反馈迭代奖励代码
FIND	2026	arXiv	G	问题规格	操作 · 真机	真机 agentic RL：VLM 依近期成功率选择练习任务并自评结果

Developer · 开发者 (9)

短名	年份	会议	Carrier	接口	身体	入选理由
RoboMorph	2024	ICRA	G	系统编辑	足式 · 仿真	LLM 进化机器人形态（硬件），最早的 Developer
VLMgineer	2025	arXiv	G	代码	操作 · 仿真	VLM 协同设计工具与动作并以仿真进化评估；硬件侧 Developer
HARBOR	2026	arXiv	G	系统编辑	操作 · 仿真	专职 coding agent 搭环境、塑奖励、调超参、训练 RL 策略（Developer Designer）
RHO	2026	arXiv	G	系统编辑	操作 · 仿真	coding agent 依奖励与执行反馈搜索修改多文件策略代码库
RATs (Playful)	2026	arXiv	G	系统编辑	操作 · 仿真+真机	游玩阶段自提任务、执行、验证并蒸馏成冻结的代码技能库，测试时复用；Developer 的 skill-library 型
ENPIRE ★	2026	arXiv	G	系统编辑	操作 · 真机	用户点名：多个 coding agent 修改策略与训练代码，真机试验决定保留或回滚
ASPIRE	2026	arXiv	G	系统编辑	操作 · 仿真+真机	coding agent 编写并精炼控制程序，从执行轨迹诊断失败，验证后入技能库（56 引）
SimEX	2026	arXiv	G	系统编辑	操作 · 仿真+真机	coding agent 在仿真中迭代工具箱代码并经少量真机试验校准
Skill2Real	2026	arXiv	G	系统编辑	操作 · 仿真+真机	Proposer-Verifier-Governor 依仿真结果保留或回滚技能代码，零样本 sim-to-real

前驱 • precursor (8)

短名	年份	会议	Carrier	接口	身体	入选理由
ZS-Planners	2022	ICML	G	技能调用	其他 • 仿真	LLM 作零样本规划者的起点
Code as Policies	2022	ICRA	G	代码	操作 • 真机	用户认定的奠基作：LLM 一次写出策略程序；不再因后果重新调用
ProgPrompt	2022	ICRA	G	代码	移动操作 • 仿真+真机	程序化提示生成带断言的任务程序
KnowNo	2023	CoRL	G	技能调用	移动操作 • 仿真+真机	不确定时向人求助的起点；人挑选选项替代了模型决策
VoxPoser	2023	CoRL	G	代码	操作 • 仿真+真机	LLM 写代码组合 3D 价值图约束，持续作用但不再调用模型
SUDD	2023	CoRL	G	技能调用	操作 • 仿真	LLM 规划并写成功检查代码生成数据再蒸馏；Teacher 的前驱
ECoT	2024	CoRL	I	执行轨迹	操作 • 真机	显式推理 VLA 的起点；每步推理但无自身记录
π 0.5	2025	arXiv	I	技能调用	移动操作 • 真机	预测子任务文本再出动作的 VLA；Harness VLA 所包装的底座（2186 引）

附录 B 资源、候补与质量控制

Benchmark 与资源 (14)

短名	年份	会议	评测的 seat	说明
Embodied Agent Interface	2024	NeurIPS	Controller	把 LLM 具身决策拆成目标解释、子目标分解、动作序列、转移建模四个模块逐项评测
PARTNR	2024	arXiv	Controller	人机协作规划与推理 benchmark (F1, 作为资源收录)
SafeAgentBench	2024	arXiv	Controller	750 个危险/安全任务, 测试具身 LLM agent 是否拒绝危险指令
VLABench	2024	ICCV	Controller	语言条件操作的大规模长程推理 benchmark (228 引)
EmbodiedEval	2025	arXiv	Controller	交互式评测 MLLM 作为具身 agent (导航、交互、问答)
EmbodiedBench	2025	ICML	Controller	24 个 MLLM 作为视觉驱动具身 agent 的综合评测, 从高层规划到低层操作
RoboCerebra	2025	NeurIPS	Controller	评测 VLM 规划者编排 VLA 控制器的长程 benchmark
Orchestration Study	2026	arXiv	Controller	对 VLM 规划者 + VLA 分层 agent 的系统性受控研究
CodeActionBench	2026	arXiv	Controller	agentic Code-as-Policy 的 25 任务 benchmark, 含隐藏物理结果
LIBERO-Agent	2026	arXiv	Controller	评测通用 agent 直接发出原生动作指令操作机器人
ASIMOV	2025	arXiv	Supervisor	自动生成机器人宪章与语义安全 benchmark
IS-Bench	2025	AAAI	Supervisor	交互式安全评测: VLM 驱动家务 agent 在过程中是否规避风险
EmboCoach-Bench	2026	arXiv	Developer	32 个 RL/IL 任务, LLM agent 迭代编写、调试训练代码
RLE-Bench	2026	arXiv	Developer	coding agent 作为机器学习工程师的资格考试

候补: 因名额没收的论文 (14)

短名	Seat	说明
Look Before You Leap	Controller · 编排型	早期 GPT-4V 闭环规划 (258 引); 与 COME-robot 重叠
MoMa-LLM	Controller · 编排型	动态场景图移动操作 (141 引); 与 BUMBLE、COME-robot 同类
Robix	Controller · 训练过的	C 型 carrier, 已有 PaLM-E; 名额给了 I 型的 MEM
AgenticNav	Controller · 直接驱动型	工具调用式导航; 导航方向已有 InstructNav
MALMM	Controller · 直接驱动型	多 agent 写代码 (×R); ×R 已有 Agentic Robot、Being-0
REAL	Controller · 直接驱动型	唯一的无人机候选; 想补 aerial 方向可换入
HarnessPAI	Developer	harness 进化; 2026 年 Developer 已有 7 篇
RAPID	Developer	从演示做 agentic 编程; 同上
AdaHVLA	Developer	自适应 harness (「harness VLA」的另一种读法); 同上
Embodied Red Teaming	Designer · Examiner	红队评测子型; 是否闭环待全文核实
RDA	Designer	reward 设计 agent; Designer 名额已满
SAGE	Designer	agentic 场景生成; 同上
CAPEX	Teacher	与 GUAVA 同型的蒸馏
Zetta	Supervisor	进化运行时 critic; seat 介于 Supervisor 与 Developer 之间

Sonnet 判定与第一轮测试集判定的对照

第一轮的测试集判定用的是复杂版规则（含 CORE-P、UNRESOLVED 等层级）。下表按第一轮的层级分行，看这一轮 Sonnet 怎么判。Sonnet 对 CORE-P 和 BOUNDARY 偏宽，人工挑选时已按定义纠正。

第一轮层级	篇数	判 core	判 precursor	判 boundary	判 resource	判 out
CORE	70	68	•	2	•	•
CORE-P	52	42	7	1	•	2
BOUNDARY	98	11	45	16	1	25
UNRESOLVED	34	13	3	5	3	10
RESOURCE	5	•	•	•	4	1
OUT	52	2	4	•	•	46

第一轮 CORE 中，两边都判 core 的 68 篇里有 65 篇主 seat 一致。

文件位置

文件	内容
docs/definition.md	正文版定义（简化）
docs/definition_draft.md	完整细则，作为附录和标注指南
data/core/core_selection.csv	人工挑选的核心表输入；增删论文改这个文件
data/core/core_table.csv	生成的核心表（含全部标签）
data/core/fine_labels.csv	1,406 篇的逐篇判定
docs/core_review.md	中文审阅清单（与附录 A 相同的入选理由）
docs/core_stats.md	按年份统计 seat 的全部数字
README.md	awesome list（英文）
HANDOFF.md	交接文档：流程、文件地图、待办与踩过的坑
scripts/build_report.py	生成这份报告